



Comprendre et prévoir la leptospirose : modélisation du risque fondée sur les données environnementales

Dr Roman THIBEAUX, Dr Pierre GENTHON, Dr Cyrille GOARANT, Dr Rodrigue GOVAN, Pr Nazha SELMAOUI



province-sud.nc



De la Rivière à l'Intelligence Artificielle : Modéliser le Risque de Leptospirose en Nouvelle-Calédonie


Du Terrain au Laboratoire : La Mesure du Risque

Resuspension bactérienne par la pluie.

Les fortes pluies lessivent les sols
contaminés par les animaux réservoirs.

Prélèvement automatisé durant les crues.


Des échantillonneurs
automatiques mesurent la
concentration de leptospires
pathogènes (pL) pendant
les épisodes cycloniques.



L'Intelligence Artificielle au Service de la Prévention


75% de la variabilité expliquée par l'IA

Les réseaux de neurones profonds
surpassent les modèles linéaires pour
prédire les concentrations.



Intégration de Facteurs Spatialisés

Analyse intégrant le type de sol, l'occupation
des terres et les données climatiques locales.



Modélisation par 'Ensemble Learning'.

Cette méthode combine
plusieurs modèles pour
prédire des zones à risque
de présence de la bactérie.


Les Déterminants du Risque Humain

Identification de la pluie, l'humidité
et le sol comme facteurs clés du
risque environnemental.

Dynamique Temporelle

Prise en compte des décalages
temporels (lag) entre les précipitations
et l'émergence du risque.

La Leptospirose : une maladie infectieuse mondiale



Plus d'1 million de cas / an


1 cas toutes les 31 secondes

60 000 décès / an

1 décès toutes les 9 minutes

La Leptospirose : un fardeau pour les populations océaniques


(et en Nouvelle Calédonie!)




« nombre de personnes malades ou nombre de cas de maladie dans une population déterminée, à un moment donné »

La Leptospirose : le cycle de contamination


Des bactéries infectieuses :
les **leptospires pathogènes**




Une contamination environnementale....




La Leptospirose en Nouvelle-Calédonie : influence des précipitations annuelles




La Leptospirose en Nouvelle-Calédonie : influence des précipitations mensuelles



La Leptospirose en Nouvelle-Calédonie : influence des précipitations hebdomadaires




La Leptospirose en Nouvelle-Calédonie : influence des précipitations hebdomadaires




Une répartition géographique sous l'influence du climat


Carte des précipitations




Carte de l'incidence de la Leptospirose en NC



Une maladie grave, particulièrement en Province Nord



- ❑ De 1 à 84 ans
- ❑ 2 x plus d'hommes que de femmes
- ❑ **Gravité** : 85% hospitalisés, dont 38% en réanimation
- ❑ **Fatalité** ~ 2-5 % (15-20% au niveau mondial)



Taux d'incidence de la Leptospirose pour 100 000 habitants par année entre 2010 et 2013

**66% des cas :
Milieu rural / tribal**

Cycle de remise en suspension des bactéries pathogènes

Nos Objectifs :

Comprendre la **dynamique de dispersion** des **bactéries pathogènes** lors d'événements météorologiques intenses.


Développer des **outils pour prédire** et **cartographier le risque** à l'échelle de la Nouvelle-Calédonie.

Notre méthodologie :


Développer des **modèles de prédiction** en utilisant différentes architectures **d'intelligence artificielle**



Collecter des échantillons **d'eaux** lors de **crues** et **quantifier** les **leptospires pathogènes**



Modèle Pluie



Modèle global spatio-temporel

Comprendre le lien entre les fortes pluies et la remise en suspension des leptospires dans les eaux de crues

Le Laboratoire à Ciel Ouvert : HydroThiem

Lieu:

Touho, Province Nord (Nouvelle-Calédonie). Un hotspot historique de la maladie.

Le Terrain:

Un bassin versant de 3 km², dégradé par les mammifères ongulés.

L'Objectif:

Comprendre la dynamique de la contamination de la rivière Thiem lors d'épisodes pluvieux intenses.

Land cover


- Humid forest
- Invasive Shrub
- Village
- Niaouli savanna

Experimental Plot



- ★ REGEN

Hydrological network

- Thiem River watershed
- CAPT watershed
- CAPT gauging station
- Raingauge
- Main river



Série temporelle de prélèvements d'eau lors d'événements cycloniques




Un effort d'échantillonnage massif : **226 prélèvements d'eau** effectués au plus fort des crues grâce à des échantillonneurs automatiques et des sondes multiparamètres. Diagnostic final par PCR.


Résultats et recommandations



Résultats et recommandations




Cyclone tropical Lucas (février 2021)



Prédiction des leptospires pathogènes dans les eaux de crues : une solution basée sur l'apprentissage automatique (« *machine learning* »)

Données d'entrées :

Données de pluviométrie avec prise en compte du contexte passé



Calcul et apprentissage :


Différentes « couches » de neurones pondèrent l'importance de chaque information

Données de sorties :

une **prédiction** de la quantité de leptospires pathogènes

Prédiction des leptospires pathogènes dans les eaux de crues : une solution basée sur l'apprentissage automatique (« *machine learning* »)


Prédictions du modèle



80%

80% de la variance expliquée par le modèle.

Explicabilité du modèle




La pluie : l'élément déclencheur...



...mais l'humidité des sols : facteur primordial

Prédire et cartographier le risque à l'échelle de la Nouvelle-Calédonie




Cartographie dynamique du risque de présence de la bactérie en Nouvelle-Calédonie

Constat :


- La bactérie vit dans les sols (en dehors des hôtes animaux) dans un contexte environnemental favorable à sa survie
- Le mécanisme de survie est encore mal compris

Problématique :

- Identifier les paramètres environnementaux et/ou autres facteurs permettant à ces bactéries de persister



L'évaluation des risques : quelle approche et quels facteurs considérés ?



Démarche

- ❑ **Modélisation spatio-temporelle** basée sur plusieurs facteurs (croisement des données de différentes sources)
- ❑ **Apprentissage des relations complexes** avec des zones :
 - Géoréférencées (aspect spatial)
 - À des instants différents (aspect temporel)
 - Décrites par des caractéristiques

L'évaluation des risques : problématiques générales




- À quels niveaux de précision spatiale et temporelle cette approche est-elle réalisable ?



- Quelles nouvelles connaissances peut-on apporter sur la distribution du risque de leptospirose en Nouvelle-Calédonie ?

Le processus ECD : Extraction de Connaissances dans les Données massives

- **L'extraction de connaissances dans les données massives (ECD)** (*KDD en anglais*) est un processus complet :




La phase de **préparation des données** prend à peu près **80 %**

- Nettoyage des données
- Sélection d'une partie des données
- Normalisation des données
- Formatage des données (en fonction des algorithmes)
- etc.

L'évaluation des risques : notre démarche


- Développement du processus complet ECD



- ✓ Facteurs **spatialisés** sous forme de **cartographie**
- ✓ Cas d'individus contractant la maladie et leur localisation (données fournies par la DASS)

L'évaluation des risques : granularité temporelle

- Les données des cas déclarés, **spatialisées**, couvrent **12 années** de données épidémiologiques, sur un pas de temps **mensuel**.
- Entre 2011 et 2022, **plus de 1 200 cas** de leptospirose ont été déclarés.




Nombre de cas de leptospirose par mois entre 2011 et 2022 en Nouvelle-Calédonie

- **Données entièrement anonymisées**
(fournies par la Direction des Affaires Sanitaires et Sociales de la Nouvelle-Calédonie)

L'évaluation des risques : granularité spatiale


- L'unité spatiale utilisée est l'**IRIS** (Ilots Regroupés pour l'Information Statistique) définie par l'ISEE :



Définition :
plus petites unités
spatiales statistiques
(≈ 1000 habitants)

Phase de préparation des données spatio-temporelles (facteurs)

- ❑ Données récoltées et/ou estimées par des méthodes mathématiques sous forme de **cartes** :
 - pour chaque observation (unité spatiale IRIS)
 - et pour chaque mois de l'année de 2011 à 2022
- ❑ Cible ou classe à prédire pour chaque unité :
 - « *Présence de risque* » : si on observe **au moins un cas** déclaré dans l'unité spatiale IRIS
 - « *Absence de risque* » sinon




Comment intégrer ces facteurs dans le modèle ?


L'évaluation des risques : Facteurs climatiques

- Données météorologiques :

- ❑ Précipitations, températures, humidité : acquisition mensuelle par Météo-France
- ❑ Traitement par interpolation des points (méthode AURELHY [BL87])




(a) Stations météorologiques.



(b) Interpolation par AURELHY.

L'évaluation des risques : Facteurs environnementaux

- Données environnementales :

Facteurs	Type (nombre)	Source
 Sol	<i>20 types de sol</i>	 Institut de Recherche pour le Développement FRANCE
 Mode d'occupation du sol	<i>22 types d'occupation du sol</i>	 GOUVERNEMENT DE LA NOUVELLE CALÉDONIE
 Modèle numérique de terrain (Topographie)	<i>Altitude du paysage</i>	 GOUVERNEMENT DE LA NOUVELLE CALÉDONIE
 Zone d'élevage	<i>Présence</i>	 OEIL
 Feu de forêt (départ mensuel)	<i>Point de début de feu</i>	 OEIL

L'évaluation des risques : Facteurs socio-démographiques

• Données socio-démographiques

↳ Organisées par IRIS et collectées par l'ISEE durant les recensements de population (2009, 2014 et 2019) :

□ Liées à la démographie :



- Population totale
- Densité de population (hab/km²)
- Nombre de personnes vivant en tribu

□ Liées à un indicateur de pauvreté :



- Nombre de ménages sans accès individuel à l'eau potable
- Nombre de ménages sans accès individuel à l'électricité
- Nombre d'anciens logements
- Nombre de personnes de la classe ouvrière.

□ Liées aux mouvements de populations :



- Nombre de personnes dont le mode de transport principal est la marche
- Nombre de personnes dont le mode de transport est le transport public
- Nombre de personnes travaillant dans une zone autre que celle de résidence

□ Liées à l'activité des personnes :



- Nombre de personnes ayant une activité agricole
- Nombre de personnes au foyer

L'évaluation des risques : Données disponibles (résumé)

Objectif : prédire l'absence ou la présence de risque de contamination par la bactérie


Les données spatio-temporelles




Un grand nombre de variables



Une contrainte majeure : le fort déséquilibre entre les deux états (présence/absence)




Modèle complexe d'apprentissage ensembliste (*Ensemble Learning*)



Modèle complexe d'apprentissage ensembliste (*Ensemble Learning*)

Étape 1 : Acquisition et Structuration des Données



Étape 2 & 3 : Entraînement, Modélisation et Prédictions

Architecture multi-modèles (Ensemble Learning)

Modèle 1
(w, b)

Modèle 2
(w, b)

Modèle 3
(w, b)

Modèle 4
(w, b)

Modèle 5
(w, b)

Modèle 6
(w, b)

Modèle 7
(w, b)

Modèle 8
(w, b)

Modèle 9
(w, b)

Modèle 10
(w, b)

Génération de prédictions individuelles

Prédiction 1
absence/présence de risque

Prédiction 2
absence/présence de risque

Prédiction 3
absence/présence de risque

Prédiction 4
absence/présence de risque

Prédiction 5
absence/présence de risque

Prédiction 6
absence/présence de risque

Prédiction 7
absence/présence de risque

Prédiction 8
absence/présence de risque

Prédiction 9
absence/présence de risque


Prédiction 10
absence/présence de risque

Agrégation



Prédiction
pondérée ($\hat{y}$)



Les résultats des dix modèles sont
sommés (Σ) et
pondérés pour
produire une
prédiction finale
unifiée notée $\hat{y}$.



Stratégie d'apprentissage du modèle

Phase d'apprentissage du modèle

Données de
2011-2020




Données d'entrée

Cas de leptospirose
de 2011 à 2020 inclus

Entraînement
des modèles

Sélection des
meilleurs modèles

Données de
2021-2022




Données d'entrée

Cas de leptospirose
en 2021 et 2022

Prédictions
pondérées

Cartographie du risque



Phase de test du modèle

Les indicateurs de performance du modèle

Présence de risque : **P**

Absence de risque : **N**

	P prédit	N Prédit
P observé	TP	FP
N observé	FN	TN

❑ **Sensibilité : 83,93 %** ➡ Taux de **bonne prédiction de présence** de bactéries sur l'unité IRIS

$$\frac{TP}{TP + FN}$$

❑ **Spécificité : 68,46 %** ➡ Taux de **bonne prédiction d'absence** de bactéries sur l'unité IRIS


$$\frac{TN}{TN + FP}$$

❑ **Précision totale : 76,19 %** ➡ Taux de **bonne prédiction globale** de bactéries sur l'unité IRIS


$$\frac{Rappel + Spécificité}{2}$$

Le calcul se fait sur les données pendant la phase test

Cartographie du risque : cartes générées pour 2021 – période chaude




Cartographie du risque : cartes générées pour 2021 – transition période fraîche / période chaude




Quels facteurs clés favorisent la survie de la bactérie ?

❏ Méthode de permutations groupées

- Groupement de facteurs (14) : *humidité et précipitations à m-1*
- Groupement de facteurs (10) : *variables dérivées du MNT (modèle numérique de terrain) & des types de sol*
- Groupement de facteurs (2) : *quelques types de végétations*




Modélisation des risques : Facteurs clés liés à la météorologie



Cluster 14 : groupe de données le plus explicatif du risque de présence de la bactérie dans le modèle


Moyenne mensuelle d'humidité ($m - 1$)
Variance mensuelle du cumul des précipitations ($m - 1$)
Moyenne mensuelle du cumul des précipitations ($m - 1$)
Médiane mensuelle du cumul des précipitations ($m - 1$)

Modélisation des risques : facteurs clés liés à la végétation



- Vergers et petits fruits
- Strates arbustive et herbacée
- Strate arborée
- Haplic Cambisols (Calcaric, Humic) associés à des Gibbsic Ferralsols (Humic) d'atolls surélevés
- Lithic Leptosols (Calcaric) associés à des Haplic Cambisols (Calcaric, Humic) sur calcaires péri-récifaux
- Gibbsic Ferralsols (Humic) d'atolls surélevés
- Haplic Fluvisols

Modélisation des risques : types de sols et topographie



Haplic Regosols associés à des Ferralic Cambisols sur roches métamorphisées

Décharges, chantiers, extraction de matériaux

Formation arborée

Écart de température ($m - 1$)

Variance d'altitude

Moyenne d'altitude


Médiane d'altitude

Ferralic Cambisols (Dystric) associés à des Haplic

Ferralsols (Dystric) sur roches métamorphisées et volcano-sédimentaires

Ferralic Cambisols (Dystric) sur roches volcano-sédim. et Haplic Ferralsols
(Dystric) sur inclusions de gabbro des péridotites du Sud

Vers un système d'alerte précoce sanitaire



□ ANTICIPER :

Réduire le risque d'exposition (nombre de cas) en **renforçant la prévention par modélisation**, basée sur les événements météorologiques (pluie)

□ PROTÉGER :

Affiner les recommandations aux populations : éviter les baignades non seulement pendant, mais aussi les jours suivant une forte pluie.

□ CIBLER :

Optimiser les ressources de santé publique en concentrant les messages sur les zones géographiques spécifiques identifiées par l'IA.





Merci de votre attention

Dr Roman THIBEAUX, Dr Pierre GENTHON, Dr Cyrille GOARANT, Dr Rodrigue GOVAN, Pr Nazha SELMAOUI

Aide à la conception du diaporama : Ludovic BREAU (D2S – Direction Science & Société, UNC)

province-sud.nc



Questions / Réponses

