

Projet SPIraL – Volets 3-4

L'intelligence artificielle au service de la santé publique :

Transfert des résultats de la recherche en modélisation et cartographie du risque de leptospirose en NC.

- *Dr Roman THIBEAUX, Dr Cyrille GOARANT (IPNC)*
- *Pr Nazha SELMAOUI, Dr Rodrigue GOVAN (UNC)*
- *Dr Pierre GENTHON (IRD)*

Métadonnées du Projet

Référence : ANR-19-CE35-0006

Période : 2020–2024


Coordinateurs : Dr. C. Goarant, Dr. R. Thibeaux



Aide à la conception du diaporama : Ludovic BREAU, Direction Science & Société (D2S) - UNC

La leptospirose : le cycle de contamination

Une contamination environnementale....



Résultats du volet 1 :
Caractérisation des habitats environnementaux des leptospires pathogènes

Facteurs Abiotiques

- pH du sol
- Composition ionique
- Éléments traces




Facteurs Biotiques


- Microbiote du sol
- Amibes libres (hôtes/refuges)

Résultats du volet 2 :
identification du microbiote associé aux leptospires dans l'environnement

Influence des précipitations **annuelles** sur l'incidence de la leptospirose en NC




Influence des précipitations mensuelles sur l'incidence de la leptospirose en NC




Une répartition géographique des cas de leptospirose sous l'influence du climat

Carte des précipitations



Carte de l'incidence de la Leptospirose en NC



Objectifs et méthodologie des volets 3 et 4 du projet SPIraL



Collecte d'échantillons d'eaux lors de crues pour quantifier leur charge en leptospires pathogènes



① Nos Objectifs : ②

Comprendre la **dynamique de dispersion** des **bactéries pathogènes** lors d'événements météorologiques intenses.

Développer des **outils pour prédire** et **cartographier le risque** à l'échelle de la Nouvelle-Calédonie.

Notre méthodologie :

Développer des **modèles de prédiction** en utilisant différentes architectures **d'intelligence artificielle**

Volet 3 :

Modélisation de la dynamique de dispersion des leptospires dans les rivières lors de fortes pluies

Modèle « pluie »

Volet 4 :

Développement d'une cartographie spatio-temporelle du risque de leptospire


Modèle global (spatio-temporel)

Volet 3 : Comprendre le lien entre les fortes pluies et la remise en suspension des leptospires dans les eaux de crues

Étude de deux bassins versants (côte ouest / côte est) entre 2020 et 2022

- ❑ Déjà connus d'un point de vue hydrologique
- ❑ Impactés par des espèces de mammifères envahissantes (cerfs, rats, cochons)

Bassin versant de la Foa (BVF) (superficie : 116 km²)




Comparaison :
effets d'échelle ?

Le Laboratoire à Ciel Ouvert : HydroThiem

Lieu:
Touho, Province Nord
(Nouvelle-Calédonie). Un
hotspot historique de la
maladie.



Le Terrain:
Un bassin versant de 3 km²,
dégradé par les mammifères
ongulés.

L'Objectif:
Comprendre la dynamique de
la contamination de la rivière
Thiem lors d'épisodes
pluvieux intenses.



Bassin versant de Haccinem à Touho (BVH) (superficie : 3 km²)


Méthodologie : Série temporelle de prélèvements d'eau lors d'événements cycloniques



Un effort d'échantillonnage massif : **226 prélèvements d'eau** effectués au plus fort des crues grâce à des échantillonneurs automatiques et des sondes multiparamètres. Diagnostic final par PCR.


Résultats et recommandations

Les cyclones comme moteurs de remobilisation bactérienne massive.



Cyclone tropical Lucas (2-3 février 2021)

Au cœur de la saison des pluies, après 2 mois de pluies abondantes




Volet 3 : Prédiction des leptospires pathogènes dans les eaux de crues

Modèle « Pluie » : une solution basée sur l'apprentissage automatique (« machine learning »)

Données d'entrées :

Données de pluviométrie avec prise en compte du contexte passé



Calcul et apprentissage :


4 couches de neurones interagissent entre elles et pondèrent l'importance de chaque information

Données de sorties :

une **prédiction** de la quantité de leptospires pathogènes


Volet 3 : Prédiction des leptospires pathogènes dans les eaux de crues : Résultats pour le bassin versant de Touho (BVH)

Prédictions du modèle



- + Données mesurées (terrain)
- Signal d'enveloppe
- Itération du meilleur modèle
- Itération du plus mauvais modèle

Explicabilité du modèle



Les variables les plus sensibles (explicatives) sont les pluies comprises entre 1 et 3 mois avant le prélèvement.

Ce modèle ne s'applique toutefois pas au bassin de La Foa

Mêmes résultats en prenant en compte la hauteur d'eau de la rivière entre 1 et 3 mois avant le prélèvement.

L'application de ce modèle au bassin de La Foa donne des résultats acceptables en termes de prédictions

Volet 3 : Prédiction des leptospires pathogènes dans les eaux de crues :

Synthèse :

Le risque n'est pas linéaire. L'état d'humidité préalable du sol décuple la charge bactérienne relâchée.

1. La charge lente


Les pluies tombées 1 à 3 mois avant le prélèvement conditionnent la survie bactérienne.

2. La saturation

L'indice d'humidité globale rend le bassin versant réactif.

3. Le déclenchement

Les pluies des dernières 24 heures agissent comme le détonateur qui vide l'éponge dans la rivière.



La pluie : l'élément déclencheur...



... mais l'humidité des sols : facteur primordial

Volet 4 : Cartographie dynamique du risque de présence de la bactérie en NC

Problématique

Comment identifier l'ensemble des facteurs permettant à ces bactéries de persister dans les sols et de contaminer l'Homme ?


Données d'entrée (spécialisées) :

- ❑ Incidence de la leptospirose
- ❑ Facteurs environnementaux
- ❑ Facteurs socio-démographiques

Données de sortie du modèle :

Cartographie dynamique du risque de présence de la bactérie dans les eaux de rivières

Modélisation spatio-temporelle : croisement des données de nombreuses sources différentes et identification des facteurs les plus explicatifs (*ensemble learning*)




Démarche globale de construction d'un modèle de prédiction spatio-temporelle du risque de leptospirose en NC


Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 1 : Collecte et traitement des données

↳ Phase de **préparation des données** : **80 % du temps total**



Acquisition & préparation des données (sélection, nettoyage, normalisation, formatage)



Spatialisation des données : l'unité spatiale utilisée est l'**IRIS** (*Ilots Regroupés pour l'Information Statistique*) définie par l'ISEE : plus petites unités spatiales statistiques (≈ 1000 habitants)

Modélisation et cartographie des risques : Démarche mise en œuvre


Étape 1 : Collecte et traitement des données

□ Données épidémiologiques (données anonymisées fournies par la DASS) : **variables à expliquer**

- Les données des cas déclarés, **spatialisés**, couvrent **12 années de suivi**, sur un pas de temps **mensuel**.
- Entre 2011 et 2022, **plus de 1 200 cas** de leptospirose ont été déclarés.

Cible ou classe à prédire pour chaque unité :

- « **Présence de risque** » : si on observe **au moins un cas** déclaré dans l'unité spatiale IRIS
- « **Absence de risque** » sinon




Nombre de cas de leptospirose par mois entre 2011 et 2022 en Nouvelle-Calédonie

Modélisation et cartographie des risques : Démarche mise en œuvre


Étape 1 : Collecte et traitement des données

Données météorologiques (variables explicatives) (fournies par Météo France NC)

- Précipitations, températures, humidité : acquisition mensuelle par Météo-France
- Traitement par interpolation des points (méthode AURELHY [BL87])



(a) Stations météorologiques.




(b) Interpolation par AURELHY.

Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 1 : Collecte et traitement des données

☐ Données environnementales (variables explicatives)

Facteurs	Type (nombre)	Source
 Sol	<i>20 types de sol</i>	 Institut de Recherche pour le Développement FRANCE
 Mode d'occupation du sol	<i>22 types d'occupation du sol</i>	 GOUVERNEMENT DE LA NOUVELLE CALÉDONIE
 Modèle numérique de terrain (Topographie)	<i>Altitude du paysage</i>	 GOUVERNEMENT DE LA NOUVELLE CALÉDONIE
 Zone d'élevage	<i>Présence</i>	 OEIL
 Feu de forêt (départ mensuel)	<i>Point de début de feu</i>	 OEIL

Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 1 : Collecte et traitement des données

□ Données socio-démographiques* (variables explicatives)

□ Liées à la démographie :



- Population totale
- Densité de population (hab/km²)
- Nombre de personnes vivant en tribu

□ Liées à un indicateur de pauvreté :



- Nombre de ménages sans accès individuel à l'eau potable
- Nombre de ménages sans accès individuel à l'électricité
- Nombre d'anciens logements
- Nombre de personnes de la classe ouvrière.

□ Liées aux mouvements de populations :



- Nombre de personnes dont le mode de transport principal est la marche
- Nombre de personnes dont le mode de transport est le transport public
- Nombre de personnes travaillant dans une zone autre que celle de résidence

□ Liées à l'activité des personnes :



- Nombre de personnes ayant une activité agricole
- Nombre de personnes au foyer

* Données organisées par IRIS et collectées par l'ISEE durant les recensements de population (2009, 2014 et 2019)

Modélisation et cartographie des risques : Démarche mise en œuvre


Étape 1 : Collecte et traitement des données

Résumé des données disponibles


Les données spatio-temporelles



Un grand nombre de variables



Une contrainte majeure : le fort déséquilibre entre les deux états (présence/absence)



Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 2 : Construction, entraînement et validation du modèle

Stratégie globale (ensemble learning) : combinaisons de modèles d'apprentissage automatique et de techniques descriptives permettant d'identifier les facteurs-clés

Architecture multi-modèles (Ensemble Learning)

Génération de prédictions individuelles

Agrégation

Modèle 1
(w, b)

Prédiction 1
absence/présence de risque

Modèle 2
(w, b)

Prédiction 2
absence/présence de risque

Modèle 3
(w, b)

Prédiction 3
absence/présence de risque

Modèle 4
(w, b)

Prédiction 4
absence/présence de risque

Modèle 5
(w, b)

Prédiction 5
absence/présence de risque

Modèle 6
(w, b)

Prédiction 6
absence/présence de risque

Modèle 7
(w, b)

Prédiction 7
absence/présence de risque

Modèle 8
(w, b)

Prédiction 8
absence/présence de risque

Modèle 9
(w, b)

Prédiction 9
absence/présence de risque

Modèle 10
(w, b)

Prédiction 10
absence/présence de risque



Prédiction
pondérée (ŷ)

Les résultats des
dix modèles sont
sommés (Σ) et
pondérés pour
produire une
prédiction finale
unifiée notée ŷ.

Les indicateurs de performance du modèle :

Présence de risque : P

Absence de risque : N

	P prédit	N Prédit
P observé	TP	FP
N observé	FN	TN

☐ **Sensibilité : 83,93 %**

$$\frac{TP}{TP + FN}$$

➡ Taux de **bonne prédiction de présence** de bactéries sur l'unité IRIS

☐ **Spécificité : 68,46 %**

$$\frac{TN}{TN + FP}$$

➡ Taux de **bonne prédiction d'absence** de bactéries sur l'unité IRIS

☐ **Précision totale : 76,19 %**

$$\frac{Rappel + Spécificité}{2}$$

➡ Taux de **bonne prédiction globale** de bactéries sur l'unité IRIS



Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 2 : Construction, entraînement et validation du modèle

Stratégie globale (ensemble learning) : combinaisons de modèles d'apprentissage automatique et de techniques descriptives permettant d'identifier les facteurs-clés)

Phase d'apprentissage du modèle

Données de
2011-2020




Données d'entrée

Cas de leptospirose
de 2011 à 2020 inclus

Entraînement
des modèles

Sélection des
meilleurs modèles

Données de
2021-2022




Données d'entrée

Cas de leptospirose
en 2021 et 2022

Prédictions
pondérées

Cartographie du risque




Phase de test du modèle

Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 3 : identification des facteurs les plus explicatifs de la présence/absence de leptospire

Méthode de permutations groupées (calcul des scores de contribution de chaque variable).


- Groupement de facteurs (cluster) n°14 : *humidité et précipitations à m-1*
- Groupement de facteurs n°10 : *variables dérivées du MNT (modèle numérique de terrain) & des types de sol*
- Groupement de facteurs n°2 : *quelques types de végétations*



Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 3 : identification des facteurs les plus explicatifs de la présence/absence de leptospire

Facteurs clés liés à la météorologie



Moyenne mensuelle d'humidité ($m - 1$)

Variance mensuelle du cumul des précipitations ($m - 1$)

Moyenne mensuelle du cumul des précipitations ($m - 1$)


Médiane mensuelle du cumul des précipitations ($m - 1$)

Cluster 14 : groupe de données le plus explicatif du risque de présence de la bactérie dans le modèle

Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 3 : identification des facteurs les plus explicatifs de la présence/absence de leptospire

Facteurs clés liés à la végétation et au type de sol



Cluster n°2

- Vergers et petits fruits
- Strates arbustive et herbacée
- Strate arborée
- Haplic Cambisols (Calcaric, Humic) associés à des Gibbsic Ferralsols (Humic) d'atolls surélevés
- Lithic Leptosols (Calcaric) associés à des Haplic Cambisols (Calcaric, Humic) sur calcaires péri-récifaux
- Gibbsic Ferralsols (Humic) d'atolls surélevés
- Haplic Fluvisols


Végétation

Type de sol

Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 3 : identification des facteurs les plus explicatifs de la présence/absence de leptospire

Facteurs clés liés au type de sol et à la topographie



Haplic Regosols associés à des Ferralic Cambisols sur roches métamorphisées

Décharges, chantiers, extraction de matériaux

Formation arborée

Écart de température ($m - 1$)

Variance d'altitude

Moyenne d'altitude

Médiane d'altitude

Ferralic Cambisols (Dystric) associés à des Haplic

Ferralsols (Dystric) sur roches métamorphisées et volcano-sédimentaires


Ferralic Cambisols (Dystric) sur roches volcano-sédim. et Haplic Ferralsols (Dystric) sur inclusions de gabbro des péridotites du Sud

Cluster n°10

Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 4 : Cartographie du risque de leptospirose


Exemple :
cartes générées pour 2021 – période chaude




Modélisation et cartographie des risques : Démarche mise en œuvre

Étape 4 : Cartographie du risque de leptospirose

Exemple :
cartes générées pour 2021 – transition
période fraîche / période chaude



Transfert des résultats de recherche : vers un système d'alerte précoce sanitaire



❑ ANTICIPER :

Réduire le risque d'exposition (nombre de cas) en **renforçant la prévention par modélisation**, basée sur les événements météorologiques (pluie)

❑ PROTÉGER :

Affiner les recommandations aux populations : éviter les baignades non seulement pendant, mais aussi les jours suivant une forte pluie.

❑ CIBLER :


Optimiser les ressources de santé publique en concentrant les messages sur les zones géographiques spécifiques identifiées par l'IA.



Transfert des résultats de recherche : inventaire des besoins pour une mise en œuvre en routine des modèles de prédiction des risques de leptospirose en NC

❑ Besoins en données scientifiques complémentaires

L'extension de l'utilisation des modèles de prédiction à d'autres bassins versants et leur mise en œuvre en routine nécessitent **une alimentation continue en données de terrain pour affiner les résultats**, d'année en année :



Transfert des résultats de recherche : inventaire des besoins pour une mise en œuvre en routine des modèles de prédiction des risques de leptospiroses en NC

❑ Besoins en ressources humaines

Le déploiement, la validation et l'exploitation des outils nécessitent le recrutement de trois profils aux compétences complémentaires :



Informaticien de niveau licence
(troisième année universitaire)

- Développer une interface web conviviale pour convertir les algorithmes en cartes de prédiction visualisables en temps réel.
- Assurer l'important travail de préparation des données d'entrée.



Doctorant ou doctorante
(contrat de trois ans)

- Collecter les données sur deux ou trois autres bassins versants à haut risque.
- Injecter ces jeux de données pour valider la pertinence du modèle hydrologique à une échelle plus large.




Ingénieur en science des données (data scientist)

- Mettre en œuvre le modèle global spatio-temporel.
- De solides connaissances en informatique et en sciences des données pour manipuler l'algorithme complexe.

Transfert des résultats de recherche : inventaire des besoins pour une mise en œuvre en routine des modèles de prédiction des risques de leptospiroses en NC

❑ Besoins en matériel informatique

La complexité des algorithmes de prédiction nécessite une puissance importante de traitement et de visualisation des données :



De la Rivière à l'Intelligence Artificielle : Modéliser le Risque de Leptospirose en Nouvelle-Calédonie


Du Terrain au Laboratoire : La Mesure du Risque

Resuspension bactérienne par la pluie.

Les fortes pluies lessivent les sols
contaminés par les animaux réservoirs.

Prélèvement automatisé durant les crues.


Des échantillonneurs
automatiques mesurent la
concentration de leptospires
pathogènes (pL) pendant
les épisodes cycloniques.



L'Intelligence Artificielle au Service de la Prévention


75% de la variabilité expliquée par l'IA

Les réseaux de neurones profonds
surpassent les modèles linéaires pour
prédire les concentrations.



Intégration de Facteurs Spatialisés

Analyse intégrant le type de sol, l'occupation
des terres et les données climatiques locales.



Modélisation par 'Ensemble Learning'.

Cette méthode combine
plusieurs modèles pour
prédire des zones à risque
de présence de la bactérie.

Les Déterminants du Risque Humain

Identification de la pluie, l'humidité
et le sol comme facteurs clés du
risque environnemental.

Dynamique Temporelle

Prise en compte des décalages
temporels (lag) entre les précipitations
et l'émergence du risque.